

# Industrial Defect Detection using Object Detection and Segmentation

Tsai Chao-wei<sup>1</sup>

© The author(s) 2026

## Abstract

本專案以 Kolektor Surface-Defect Dataset 2 作為工業表面瑕疵偵測資料集，建立以 YOLOv8 為基礎之 object detection 與 segmentation 模型。由於資料集中正常樣本遠多於瑕疵樣本，本專案先透過 normal-sample downsampling 處理類別不平衡問題，再將原始 bitmap mask 標註轉換為 YOLO detection 與 YOLO segmentation 格式。實驗結果顯示，YOLOv8n detection model 於 object-level test set 上達到  $mAP@0.5 = 0.767$ ；進一步將 detection confidence score 轉換為 image-level defect score 後，模型於 image-level defect screening 任務上達到  $F1-score = 0.852$ 、 $ROC-AUC = 0.960$  與  $PR-AUC = 0.904$ 。此外，本專案亦建立 patch-based segmentation dataset，以改善小面積、低對比與不規則瑕疵在 segmentation 任務中的學習效果。整體而言，detection model 在瑕疵篩選與定位任務上表現較穩定，而 segmentation model 則可作為像素級瑕疵輪廓分析之延伸。**Key-**

**words:** Industrial Defect Detection; Object Detection; Segmentation; YOLOv8; Kolektor Surface-Defect Dataset 2

## 1 Introduction

工業表面瑕疵偵測是電腦視覺在製造業品質控管中的重要應用。傳統人工檢測方式容易受到檢測者經驗、疲勞程度與主觀判斷影響，且在大量產品影像中進行逐一檢查時，效率與穩定性皆受到限制。因此，建立自動化瑕疵偵測模型，可協助提升檢測一致性並降低人工成本。

本專案以深度學習方法處理工業表面瑕疵偵測問題，主要包含三個層次。第一個層次為 image-level defect screening，目標是判斷整張影像是否包含瑕疵；第二個層次為 object detection，目標是以 bounding box 標示瑕疵所在位置；第三個層次為 segmentation，目標是進一步預測瑕疵區域的像素級輪廓。由於原始資料提供 bitmap mask 標註，因此本專案不僅可建立 detection baseline，也能進一步評估 segmentation model 在細部瑕疵定位上的表現。

## 2 Dataset Description and Preprocessing

本專案使用 Kolektor Surface-Defect Dataset 2 作為工業表面瑕疵偵測資料集。該資料集包含正常表面影像與具有瑕疵之表面影像，適合用於建立工業瑕疵偵測模型。資料中的正常影像不含瑕疵標註；瑕疵影像則提供像素級 bitmap mask 標註，因此本專案可同時進行

bounding box object detection 與 pixel-level segmentation 兩類任務。


## 2.1 Dataset Composition

原始資料集分為訓練集與測試集。訓練集共有 2,332 張影像，其中包含 246 張瑕疵影像與 2,086 張正常影像；測試集共有 1,004 張影像，其中包含 110 張瑕疵影像與 894 張正常影像。整體而言，資料集共包含 3,336 張影像，其中瑕疵影像僅有 356 張，正常影像則有 2,980 張。由此可見，資料集中正常樣本遠多於瑕疵樣本，具有明顯的類別不平衡問題。

**Table 1:** Composition of the original KolektorSDD2 dataset

| Dataset | Normal Images | Defect Images | Total Images | Defect Ratio |
|---------|---------------|---------------|--------------|--------------|
| Train   | 2,086         | 246           | 2,332        | 10.55%       |
| Test    | 894           | 110           | 1,004        | 10.96%       |
| Total   | 2,980         | 356           | 3,336        | 10.67%       |

換言之，瑕疵影像只佔整體資料集約 10.67%。這表示若直接使用原始資料訓練模型，模型可能更容易學到正常背景，而不是有效學習少數的瑕疵樣本。因此，後續模型訓練必須特別處理類別不平衡問題。



**Figure 1:** Examples from the Kolektor Surface-Defect Dataset 2.

## 2.2 Annotation Format

原始標註檔以 JSON 格式儲存。若影像為正常樣本，則標註檔中的 objects 欄位為空；若影像為瑕疵樣本，則標註檔中包含 bitmap 型式之瑕疵區域標註。此 bitmap mask 代表瑕疵在影像中的像素位置，因此可用於建立 segmentation label。

為了配合 YOLO 模型訓練，本專案將原始標註轉換為兩種格式。第一種為 object detection 格式。本專案將每一個 bitmap mask 轉換為其外接矩形 bounding box，並輸出為 YOLO detection label 格式。此格式包含類別編號、bounding box 中心座標、寬度與高度，且所有座標皆經過影像寬高正規化。

第二種為 segmentation 格式。本專案將 bitmap mask 轉換為 polygon contour，並輸出為 YOLO segmentation label 格式。此格式以多邊形頂點描述瑕疵區域輪廓，因此能讓 YOLOv8 segmentation model 學習像素級瑕疵形狀。

## 2.3 Train, Validation, and Test Split

為了在模型訓練過程中監控泛化能力，本專案將原始訓練集進一步切分為 train subset 與 validation subset。切分後，train subset 共有 1,866 張影像，其中包含 197 張瑕疵影像與 1,669 張正常影像；validation subset 共有 466 張影像，其中包含 49 張瑕疵影像與 417 張正常影像。原始 test set 則保持不變，作為最終模型評估使用。

**Table 2:** Data split used for model training and evaluation

| Dataset    | Normal Images | Defect Images | Total Images | Purpose          |
|------------|---------------|---------------|--------------|------------------|
| Train      | 1,669         | 197           | 1,866        | Model training   |
| Validation | 417           | 49            | 466          | Model selection  |
| Test       | 894           | 110           | 1,004        | Final evaluation |

本專案保留原始 test set 的資料分布，避免因為測試資料被重新抽樣而高估模型表現。換言之，validation set 用於模型選擇與超參數比較，而 test set 僅用於最終模型評估。

## 2.4 Class Imbalance Handling

由於正常影像數量遠高於瑕疵影像，若直接使用原始訓練資料進行模型訓練，模型容易偏向預測正常背景，進而降低對瑕疵樣本的偵測能力。為降低類別不平衡對模型訓練造成的影響，本專案採用 normal-sample downsampling 策略。

具體而言，在 training subset 中，本專案保留所有 197 張瑕疵影像，並從 1,669 張正常影像中隨機抽取 600 張作為訓練資料。經過 downsampling 後，balanced training set 共包含 797 張影像，其中包含 197 張瑕疵影像與 600 張正常影像。

**Table 3:** Training data after normal-sample downsampling

| Dataset        | Normal Images | Defect Images | Total Images |
|----------------|---------------|---------------|--------------|
| Balanced Train | 600           | 197           | 797          |
| Validation     | 417           | 49            | 466          |
| Test           | 894           | 110           | 1,004        |

Validation set 與 test set 則不進行 downsampling，以維持其原始資料分布。此設計可使模型在訓練階段接觸到相對較高比例的瑕疵樣本，同時仍能在原始分布下評估最終表現。

## 2.5 Patch-based Segmentation Dataset

由於 KolektorSDD2 中的瑕疵通常具有小面積、低對比、細長或不規則形狀等特性，若直接將整張影像縮放至模型輸入尺寸，瑕疵區域在影像中的相對比例可能過小，導致 segmentation model 難以有效學習瑕疵輪廓。因此，本專案進一步建立 patch-based segmentation dataset。

Patch-based 方法的核心概念是將原始影像切分為較小的局部影像區塊，使瑕疵在模型輸入中的相對比例提高。對於 training subset，本專案以瑕疵 connected component 為中心建立 positive patches，並同時從正常影像或瑕疵影像中的非瑕疵區域抽取 negative patches。對於 validation 與 test set，則採用 sliding window 方式系統性切分影像，以確保評估時能覆蓋完整影像區域。

本專案主要測試兩種 patch-based segmentation 設定。第一種設定使用 patch size 224 與 stride 112；第二種設定使用 patch size 320 與 stride 160。前者可進一步放大局部瑕疵，但保留的上下文資訊較少；後者則在放大瑕疵與保留周邊紋理資訊之間取得較佳平衡。

**Table 4:** Patch-based segmentation settings

| Setting   | Patch Size | Stride | Description                                     |
|-----------|------------|--------|-------------------------------------------------|
| Patch-224 | 224        | 112    | Stronger local defect magnification             |
| Patch-320 | 320        | 160    | Better balance between local defect and context |

## 2.6 Summary of Data Preparation

整體而言，本專案之資料前處理流程包含四個主要階段。首先，依據標註檔區分正常影像與瑕疵影像。其次，將 bitmap mask 轉換為 YOLO detection 與 YOLO segmentation 格式。第三，透過 normal-sample downsampling 處理類別不平衡問題。最後，建立 patch-based segmentation dataset，以改善小面積瑕疵在 segmentation 任務中的學習效果。

## 3 Modeling Strategy

本專案分別建立 YOLOv8 object detection model 與 YOLOv8 segmentation model. Object detection model 用於建立瑕疵位置偵測 baseline，主要目標是以 bounding box 判斷影像中是否存在瑕疵區域；segmentation model 則進一步利用原始 bitmap mask 標註，預測瑕疵區域之像素級輪廓。此外，本專案亦將 detection model 的最高 confidence score 轉換為 image-level defect score，用以評估模型作為瑕疵影像篩選器的能力。

在 object detection 任務中，本專案將原始 bitmap mask 轉換為 bounding box label，並使用 YOLOv8n 作為主要模型架構。由於原始資料存在明顯類別不平衡，因此本專案保留所有瑕疵影像，並將訓練集中正常影像下採樣至 600 張，以增加模型在訓練階段接觸瑕疵樣本的比例。最終 object detection model 採用 YOLOv8n、輸入影像尺寸 768，並以 100 epochs 進行訓練。

在 segmentation 任務中，本專案使用 YOLOv8n-seg 作為主要模型架構。首先，本專案以 full-image segmentation 作為 baseline，直接使用完整影像與對應之 polygon mask label 進行訓練。然而，由於瑕疵區域通常具有小面積、低對比與不規則形狀等特性，完整影像縮放後可能使瑕疵區域在模型輸入中過小。因此，本專案進一步建立 patch-based segmentation dataset，分別測試 patch size 224 與 patch size 320 兩種設定。實驗結果顯示，patch size 320 在保留局部瑕疵特徵與周邊紋理資訊之間取得較佳平衡，因此作為本專案之主要 segmentation model。

模型表現以 precision、recall、F1-score、mAP@0.5 與 mAP@0.5:0.95 進行評估。其中，precision 衡量模型預測為瑕疵之結果中有多少比例為正確預測；recall 衡量實際瑕疵中有多少比例被模型成功偵測；F1-score 為 precision 與 recall 的調和平均；mAP@0.5 衡量 IoU threshold 為 0.5 時的平均精度；mAP@0.5:0.95 則進一步在多個 IoU threshold 下計算平均精度，因此可視為較嚴格的定位品質指標。在 image-level defect screening 任務中，本專案另採用 accuracy、balanced accuracy、ROC-AUC 與 PR-AUC 評估模型對 normal images 與 defect images 的區分能力。

## 4 Experimental Results

### 4.1 Image-level Defect Screening Results

除 object-level defect localization 外，本專案亦進一步評估模型在 image-level defect screening 任務上的表現。此任務之目標並非評估 bounding box 的定位精度，而是判斷整張影像是否包含瑕疵。具體而言，對於每一張測試影像，本專案取 YOLOv8 detection model 所輸出之最高 confidence score 作為該影像的 defect score；若此分數高於指定 threshold，則將該影像判定為 defect image，否則判定為 normal image。

Threshold 的選擇先於 validation set 上進行搜尋，並以 F1-score 最高者作為最終門檻。Validation set 上最佳 threshold 為 0.32，接著將此 threshold 固定後套用於 test set，以避免直接依據 test set 調整門檻。表 5 顯示 image-level defect screening 於 test set 上的評估結果。

**Table 5:** Image-level defect screening result on the test set

| Threshold | Accuracy | Balanced Acc. | Precision | Recall | F1    | ROC-AUC | PR-AUC |
|-----------|----------|---------------|-----------|--------|-------|---------|--------|
| 0.32      | 0.968    | 0.910         | 0.868     | 0.836  | 0.852 | 0.960   | 0.904  |

結果顯示，模型在 image-level defect screening 任務上達到 accuracy = 0.968、balanced accuracy = 0.910、F1-score = 0.852、ROC-AUC = 0.960 與 PR-AUC = 0.904。由於 test set 中 normal images 明顯多於 defect images，因此僅觀察 accuracy 可能高估模型表現；然而，本模型同時具有 0.910 的 balanced accuracy 與 0.904 的 PR-AUC，表示模型並非僅偏向預測 normal class，而是具備良好的 normal / defect 區分能力。

**Table 6:** Confusion matrix of image-level defect screening on the test set

|               | Predicted Normal | Predicted Defect |
|---------------|------------------|------------------|
| Actual Normal | 880              | 14               |
| Actual Defect | 18               | 92               |


由 confusion matrix 可知，在 894 張 normal images 中，模型正確判斷 880 張，僅有 14 張被誤判為 defect；在 110 張 defect images 中，模型成功偵測 92 張，漏判 18 張。此結果顯示，YOLOv8 detection model 不僅能提供 object-level defect localization，也能作為有效的 image-level defect screening model。

### 4.2 Object Detection Results

表 7 顯示最終 object detection model 於 test set 上的表現。此模型採用 YOLOv8n，並使用 normal-sample downsampling 後之訓練資料進行訓練。測試結果顯示，模型在 test set 上達到 precision = 0.764、recall = 0.708、mAP@0.5 = 0.767 與 mAP@0.5:0.95 = 0.402。此結果表示模型已能偵測多數較明顯的瑕疵區域，但在較嚴格的定位標準下，bounding box localization 仍有改善空間。

**Table 7:** Final object detection result on the test set

| Model             | Precision | Recall | mAP@0.5 | mAP@0.5:0.95 |
|-------------------|-----------|--------|---------|--------------|
| YOLOv8n Detection | 0.764     | 0.708  | 0.767   | 0.402        |

**Figure 2:** Qualitative examples of object detection results.

由 qualitative examples 可觀察到，true positive cases 通常具有較明顯的局部紋理異常，因此模型能成功以 bounding box 標示瑕疵區域。相較之下，false positive cases 多來自正常表面紋理、亮度變化或局部雜訊，使模型將非瑕疵區域誤判為 defect region；false negative cases 則通常對應於低對比、小面積或邊界不明顯的瑕疵，使模型難以從背景紋理中區分異常區域。此結果顯示，本資料集中最具挑戰性的案例並非大型且明顯的瑕疵，而是與正常表面紋理相似、邊界不清楚或面積較小的細微缺陷。

### 4.3 Normal-sample Downsampling Ablation Study

為了進一步檢驗 normal-sample downsampling 對模型表現的影響，本專案進行 normal-sample ratio 之 ablation study。此實驗的目的並非重新尋找全新模型架構，而是檢查 training set 中 normal images 的保留數量是否會影響模型對 defect regions 的學習效果。具體而言，本專案固定保留 training subset 中所有 197 張 defect images，並分別設定 normal images 數量為 full normal、400、600、800 與 1000。Validation set 與 test set 在所有設定中皆保持不變，以避免因評估資料分布不同而造成比較偏誤。

在實驗流程上，本專案先以 validation set 選擇各設定下的最佳 model checkpoint，接著於 test set 上評估 object-level detection performance。此外，為了比較不同 downsampling settings 在 image-level defect screening 任務上的效果，本專案亦將每張影像的最高 detection confidence score 視為 defect score，並於 validation set 上搜尋最佳 threshold，再將該 threshold 固定後套用於 test set。此設計可同時觀察 normal-sample ratio 對 bounding box localization 與 image-level screening 的影響。



**Table 8:** Ablation study of normal-sample downsampling

| Setting     | Normal | Defect | Obj. Precision | Obj. Recall | mAP@0.5 | mAP@0.5:0.95 | Image F1 | PR-AUC | FP/FN |
|-------------|--------|--------|----------------|-------------|---------|--------------|----------|--------|-------|
| Full normal | 1669   | 197    | 0.725          | 0.588       | 0.640   | 0.303        | 0.853    | 0.904  | 11/20 |
| n400        | 400    | 197    | 0.650          | 0.639       | 0.628   | 0.317        | 0.798    | 0.898  | 33/15 |
| n600        | 600    | 197    | 0.764          | 0.708       | 0.767   | 0.402        | 0.852    | 0.904  | 14/18 |
| n800        | 800    | 197    | 0.648          | 0.672       | 0.656   | 0.329        | 0.850    | 0.888  | 13/19 |
| n1000       | 1000   | 197    | 0.727          | 0.664       | 0.696   | 0.358        | 0.889    | 0.907  | 5/18  |

表 8 顯示，normal-sample ratio 會明顯影響不同任務層次的模型表現。若以 object-level localization 作為主要目標，normal = 600 的設定取得最佳結果，其 object precision = 0.764、object recall = 0.708、mAP@0.5 = 0.767，且 mAP@0.5:0.95 = 0.402，皆高於 full normal 與其他 downsampling settings。此結果表示，適度降低 normal samples 的比例，可使模型在訓練階段更集中地學習少數 defect samples，進而提升 bounding box localization performance。

然而，若從 image-level defect screening 的角度觀察，normal = 1000 的設定取得最高 image-level F1-score = 0.889 與 PR-AUC = 0.907，且 false positives 僅有 5 張。這表示較多 normal samples 可提升模型對 normal images 的辨識穩定性，進而降低誤報率。因此，不同 downsampling settings 反映出 object-level localization 與 image-level screening 之間的 trade-off。本專案最終仍以 normal = 600 作為主要 detection model，原因是本研究主軸著重於 defect localization，而該設定在 object-level mAP 指標上表現最佳。

#### 4.4 Segmentation Results

表 9 比較不同 segmentation 設定於 validation set 上的 mask performance. Full-image segmentation 的 recall 較低，表示直接以完整影像訓練時，模型較容易漏掉小面積瑕疵。相較之下，patch-based segmentation 可提升模型對瑕疵區域的辨識能力。其中，patch size 320 的設定在 mask precision、mask mAP@0.5 與 mask mAP@0.5:0.95 上皆優於 patch size 224，因此本專案將 patch size 320 作為最終 segmentation 設定。

**Table 9:** Validation comparison of segmentation models

| Model                      | Mask Precision | Mask Recall | Mask mAP@0.5 | Mask mAP@0.5:0.95 |
|----------------------------|----------------|-------------|--------------|-------------------|
| Full-image YOLOv8n-seg     | 0.762          | 0.440       | 0.615        | 0.257             |
| Patch-224 YOLOv8n-seg      | 0.742          | 0.603       | 0.616        | 0.266             |
| Patch-320 YOLOv8n-seg      | 0.868          | 0.604       | 0.717        | 0.294             |
| Patch-320-pos8 YOLOv8n-seg | 0.786          | 0.571       | 0.600        | 0.280             |

此外，本專案亦嘗試增加 defect-centered positive patches 的數量，將每個 connected component 周圍產生的 positive patches 由 4 張增加至 8 張。然而，Patch-320-pos8 的 validation performance 並未優於原始 Patch-320 設定，顯示單純增加 positive patches 數量不一定能改善 segmentation 泛化能力。因此，後續仍採用 Patch-320 YOLOv8n-seg 作為主要 segmentation 設定。

表 10 進一步呈現 patch size 320 segmentation model 於 test set 上的 mask-level performance. 結果顯示，該模型在 patch-level test set 上達到 mask precision = 0.778、mask recall = 0.573、mask mAP@0.5 = 0.689 與 mask mAP@0.5:0.95 = 0.329。此結果表示 patch-based




segmentation 能有效學習部分瑕疵區域，但對於細小、低對比與不規則形狀的瑕疵，仍存在漏偵測與像素級定位不精準的問題。

**Table 10:** Final patch-based segmentation result on the test set

| Model                 | Mask Precision | Mask Recall | Mask mAP@0.5 | Mask mAP@0.5:0.95 |
|-----------------------|----------------|-------------|--------------|-------------------|
| Patch-320 YOLOv8n-seg | 0.778          | 0.573       | 0.689        | 0.329             |

圖 3 呈現 patch-based segmentation model 的 qualitative example。相較於 object detection 僅需預測瑕疵的大致位置，segmentation model 必須進一步預測瑕疵的像素級輪廓，因此對於細長、低對比或邊界不明顯的瑕疵更具挑戰。



**Figure 3:** Qualitative example of patch-based segmentation. The green overlay indicates the ground truth mask, while the red overlay indicates the predicted mask.

#### 4.5 Overall Model Comparison

表 11 彙整本專案目前三個層次的模型結果。需要注意的是，image-level defect screening 是以整張影像是否包含瑕疵作為評估單位；object detection 是以 bounding box localization 作為評估單位；patch-based segmentation 則是以切分後的 test patches 作為評估單位。因此，三者並非完全相同的任務，但可共同呈現模型在不同瑕疵偵測層次上的能力。

此外，表 11 中的 image-level screening 結果對應於本專案主要 final model，也就是 normal = 600 的 YOLOv8n detection model。若將 image-level screening 作為唯一優化目標，前述 ablation study 顯示 normal = 1000 可取得更高的 F1-score 與較低的 false positives；然而，由於本專案主要關注 defect localization，因此整體比較仍以 normal = 600 的 detection model 作為主要 final model。

**Table 11:** Overall comparison of defect detection tasks

| Task / Model               | Precision | Recall | Main Metric 1        | Main Metric 2             |
|----------------------------|-----------|--------|----------------------|---------------------------|
| Image-level Screening      | 0.868     | 0.836  | F1 = 0.852           | PR-AUC = 0.904            |
| YOLOv8n Detection          | 0.764     | 0.708  | mAP@0.5 = 0.767      | mAP@0.5:0.95 = 0.402      |
| Patch-320 YOLOv8n-seg Mask | 0.778     | 0.573  | Mask mAP@0.5 = 0.689 | Mask mAP@0.5:0.95 = 0.329 |

整體而言，本專案結果可分為三個層次。第一，於 image-level defect screening 任務中，模型能有效判斷整張影像是否包含瑕疵，並在 test set 上達到  $F1\text{-score} = 0.852$  與  $PR\text{-AUC} = 0.904$ ，顯示模型具有良好的瑕疵影像篩選能力。第二，於 object-level detection 任務中，YOLOv8n detection model 在 test set 上達到  $mAP@0.5 = 0.767$ ，表示模型能大致定位多數瑕疵區域。第三，於 pixel-level segmentation 任務中，patch-based YOLOv8n-seg model 可進一步提供瑕疵區域之 mask prediction，但其 mask recall 與 mask  $mAP@0.5:0.95$  仍低於 detection model，顯示小面積與低對比瑕疵的像素級定位仍具有挑戰。

因此，本專案最終以 YOLOv8n detection model 作為主要模型，並將 image-level defect screening 作為實務應用上的重要評估方式；segmentation model 則作為延伸分析，用以探討模型在更細緻瑕疵輪廓預測上的能力與限制。

## 5 Discussion

本專案結果顯示，normal-sample downsampling 對於提升 defect detection 表現具有關鍵作用。由於原始資料集中 normal images 的比例遠高於 defect images，若未處理類別不平衡問題，模型容易傾向學習正常背景，而無法充分學習少數瑕疵樣本的局部特徵。透過保留所有 defect images 並調整 normal training images 數量，模型能在訓練階段接觸到相對更高比例的瑕疵樣本，進而提升對 defect regions 的辨識能力。

Ablation study 進一步顯示，normal-sample ratio 的最佳設定會隨任務目標而改變。若重視 object-level localization，normal = 600 的設定在  $mAP@0.5$  與  $mAP@0.5:0.95$  上表現最佳，表示該設定較能提升 bounding box localization performance。若重視 image-level defect screening，normal = 1000 則取得較高 F1-score 與較低 false positives，顯示較多 normal samples 有助於降低正常影像被誤判為瑕疵的機率。因此，downsampling ratio 不應被視為單一固定選擇，而應根據實際應用目標進行調整。

另一方面，segmentation 任務雖然能提供更細緻的像素級 defect mask，但其難度高於 object detection。對本資料集而言，瑕疵通常具有小面積、低對比、細長或不規則形狀等特性，因此模型即使能大致定位瑕疵區域，也不一定能準確切出完整瑕疵輪廓。Patch-based segmentation 可改善 full-image segmentation 中瑕疵比例過小的問題，但也可能因切分影像而減少全域上下文資訊。因此，patch-based segmentation 雖能提升部分 mask-level performance，但仍無法完全取代 object detection model。

此外，image-level defect screening 結果顯示，detection model 的最高 confidence score 可作為有效的 defect image score。此結果具有實務意義，因為工業品檢流程中通常會先判斷產品影像是否異常，再進一步檢查異常位置與瑕疵型態。因此，即使 object-level localization 與 pixel-level segmentation 仍有改善空間，image-level screening 仍可作為自動化品檢系統的第一階段篩選工具。

需要注意的是，本專案之 downsampling ablation 係基於單次 normal-sample subset 進行比較，因此不同 normal images 抽樣結果可能造成一定程度的變異。後續若進一步延伸，可針對各 downsampling setting 重複多個 random seeds，並以 mean  $\pm$  standard deviation 呈現模型表現，以更穩健地評估 normal-sample ratio 對模型性能的影響。

## 6 Conclusion

本專案以 Kolektor Surface-Defect Dataset 2 為基礎，建立 YOLOv8-based industrial defect detection framework，並從 image-level screening、object-level detection 與 pixel-level segmentation 三個層次評估模型表現。首先，本專案將原始 bitmap mask 標註轉換為 YOLO

detection 與 YOLO segmentation 格式，使模型能同時進行 bounding box localization 與 pixel-level mask prediction。其次，針對資料集中 normal images 遠多於 defect images 的問題，本專案採用 normal-sample downsampling 策略，並進一步透過 ablation study 比較不同 normal-sample ratio 對模型表現的影響。

實驗結果顯示，normal = 600 的 YOLOv8n detection model 在 object-level test set 上達到  $\text{mAP}@0.5 = 0.767$  與  $\text{mAP}@0.5:0.95 = 0.402$ ，具備良好的瑕疵定位能力。進一步將 detection confidence 轉換為 image-level defect score 後，該模型於 test set 上達到  $\text{F1-score} = 0.852$ 、 $\text{ROC-AUC} = 0.960$  與  $\text{PR-AUC} = 0.904$ ，顯示其具有穩定的瑕疵影像篩選能力。Normal-sample downsampling ablation 亦顯示，normal = 600 在 object-level detection 指標上表現最佳，而 normal = 1000 在 image-level screening 指標上更具優勢，說明不同任務目標下可能需要不同的資料取樣策略。

在 segmentation 任務中，patch-based YOLOv8n-seg model 能改善 full-image segmentation 對小瑕疵辨識不足的問題，但 mask recall 與 mask  $\text{mAP}@0.5:0.95$  仍低於 detection model，表示小面積、低對比與不規則瑕疵的像素級定位仍具挑戰。整體而言，本專案以 normal = 600 的 YOLOv8n detection model 作為主要 final model，並以 image-level defect screening 作為實務應用上的重要成果；segmentation model 則作為延伸分析，提供對像素級 defect localization 的進一步探討。