

國立臺北大學統計學研究所

CNN-Based Image Deblurring with Residual Learning

基於殘差學習之卷積神經網路影像去模糊

本專案以影像去模糊為主題，建立以卷積神經網路為基礎之影像復原模型。研究重點包含模糊影像與清晰影像之成對資料建構、影像前處理、殘差式 CNN 模型設計、模型訓練、fine-tuning 與去模糊結果評估。本文主要以 V2 Ultimate 作為核心模型，並在其基礎上進一步進行 V2 Ultimate-FT 微調，以提升最終影像復原表現。

學生：蔡詔崙

英文姓名：Tsai Zhou-Wei

工具：Python / PyTorch / OpenCV / CNN

主題：Image Deblurring / Residual Learning

日期：June 20, 2026

Contents

1	Introduction	3
2	Related Background	3
2.1	Image Deblurring	3
2.2	CNN for Image Restoration	3
2.3	Residual Learning	4
3	Problem Formulation	4
4	Dataset and Preprocessing	4
5	Proposed Method	5
5.1	Overview	5
5.2	Model Evolution	6
5.3	V2 Ultimate Model Architecture	7
5.4	Channel Attention	8
5.5	Loss Functions	8
6	Experimental Settings	9
7	Experimental Results	10
7.1	Training Curves of V2 Ultimate	10
7.2	Quantitative Results	11
7.3	Ablation Study	11
7.4	Model Efficiency and Inference Speed	12
7.5	Qualitative Results	13
7.6	Challenging Case Analysis	14
8	Discussion	14
9	Conclusion	15

Abstract

影像模糊是電腦視覺與影像處理中常見的退化問題，可能由相機晃動、物體移動、對焦不準或影像擷取過程中的雜訊干擾所造成。模糊影像會使邊緣、紋理與細節資訊變得不清楚，進而影響後續影像辨識、目標偵測或人工判讀的準確性。因此，如何從模糊影像中恢復較清晰的影像內容，是影像復原任務中的重要問題。

本專案建立一個以卷積神經網路為基礎的影像去模糊模型，並引入殘差學習概念，使模型不直接學習完整清晰影像，而是學習模糊影像與清晰影像之間的差異。本文主要以 V2 Ultimate 作為核心模型。該模型採用 enhanced residual blocks、channel attention、residual scaling、data augmentation、exponential moving average 與 cosine learning rate scheduler，以提升模型訓練穩定性與泛化能力。接著，本研究再以 V2 Ultimate 的最佳 checkpoint 作為初始權重，進一步建立 V2 Ultimate-FT fine-tuned model 作為最終測試模型。

實驗結果顯示，V2 Ultimate-FT 模型在 Set5 測試集上將平均 PSNR 由 21.55 dB 提升至 27.20 dB，SSIM 由 0.878 提升至 0.980；在 Set14 測試集上，PSNR 由 20.57 dB 提升至 24.91 dB，SSIM 由 0.881 提升至 0.961。整體 Set5 與 Set14 合併結果顯示，模型可將 PSNR 提升 4.69 dB，並將 SSIM 提升 0.086，表示本專案所建立之 CNN-based residual deblurring model 能有效改善模糊影像品質。

Keywords: Image Deblurring; Convolutional Neural Network; Residual Learning; Channel Attention; Fine-Tuning; PyTorch

1 Introduction

影像去模糊 (image deblurring) 是影像復原 (image restoration) 中的重要任務，其目標是從受到模糊退化影響的影像中，恢復出較接近原始清晰影像的結果。影像模糊的來源可能包含相機晃動、物體移動、景深限制、對焦不準或影像擷取過程中的雜訊干擾。當影像中的邊緣、紋理與局部細節變得不清楚時，不僅會降低視覺品質，也可能影響後續電腦視覺任務，例如影像分類、物件偵測、瑕疵檢測與醫學影像分析。

傳統影像去模糊方法通常需要對模糊核 (blur kernel) 進行假設或估計，再透過反卷積或最佳化方法恢復清晰影像。然而，在真實場景中，模糊型態往往並非單一且固定，且可能同時受到不同方向、不同強度與不同區域的模糊影響。因此，若僅依賴手工設計的影像復原方法，通常難以穩定處理複雜且多樣的模糊影像。

近年來，深度學習方法被廣泛應用於影像復原任務。卷積神經網路 (Convolutional Neural Network, CNN) 能透過大量資料自動學習模糊影像與清晰影像之間的映射關係，因此不需要明確指定模糊核型態。本專案即以 CNN 為主要模型架構，建立影像去模糊模型，並進一步加入殘差學習 (residual learning) 設計，使模型專注於學習模糊影像中需要被修正的細節資訊。

本專案的主要目標可分為三點。第一，建立模糊影像與清晰影像之間的成對訓練流程，使模型能夠從資料中學習去模糊轉換。第二，設計 CNN-based residual deblurring model，並透過 enhanced residual blocks 與 channel attention 提升模型對影像邊緣與紋理細節的復原能力。第三，透過 PSNR、SSIM 與視覺化結果，比較模型輸入影像、去模糊輸出影像與目標清晰影像之間的差異，評估模型在影像復原任務上的表現。

2 Related Background

2.1 Image Deblurring

影像去模糊可被視為一種 inverse problem。給定一張退化後的模糊影像，模型需要推估其對應的清晰影像。然而，影像模糊通常會造成高頻資訊流失，使得邊緣、細線條與紋理結構變得不清楚。若模糊程度過強，部分細節甚至可能難以完整恢復。因此，影像去模糊不只是單純讓影像變銳利，而是需要在降低模糊、保留結構與避免失真之間取得平衡。

2.2 CNN for Image Restoration

CNN 適合影像復原任務，原因在於 convolutional layers 能夠利用局部感受野擷取影像中的空間結構。對於去模糊問題而言，低層卷積可學習邊緣與亮度變化，中間層可學習局部紋理與模糊型態，而較深層的特徵則可整合更大範圍的影像上下文。相較於傳統方法，CNN 不需要明確指定模糊核，而是透過資料學習模糊影像與清晰影像之間的映射。

2.3 Residual Learning

在影像去模糊任務中，模糊影像與清晰影像通常共享大部分低頻結構，例如整體輪廓、物體位置與主要亮度分布。真正需要修正的部分多集中在邊緣、紋理與高頻細節。因此，本專案採用 residual learning，使模型學習模糊影像與清晰影像之間的差異，而非直接重新生成完整清晰影像。此設計能降低模型學習難度，並使模型更集中於細節修正。

3 Problem Formulation

影像去模糊任務可被視為一個監督式學習問題。給定一張模糊影像 X ，模型的目標是預測其對應的清晰影像 Y 。若使用一般直接映射方法，模型會學習以下函數：

$$\hat{Y} = f_{\theta}(X),$$

其中， $f_{\theta}(\cdot)$ 表示由參數 θ 所定義的 CNN 模型， $\hat{Y}$ 為模型預測之去模糊影像。

然而，直接從模糊影像重建完整清晰影像，對模型而言可能較為困難。原因在於模糊影像與清晰影像在整體亮度與主要結構上可能高度相似，真正需要修正的部分通常集中在邊緣、紋理與高頻細節。因此，本專案採用殘差學習概念，使模型學習模糊影像與清晰影像之間的差異：

$$R = Y - X,$$

其中， R 表示清晰影像與模糊影像之間的殘差。模型輸出可表示為：

$$\hat{R} = f_{\theta}(X).$$

最後再將模型預測的殘差加回原始模糊影像，得到去模糊結果：

$$\hat{Y} = X + \hat{R}.$$

此設計的優點在於模型不需要重新產生整張影像，而是專注於學習需要補強或修正的局部細節。因此，殘差學習有助於降低模型學習難度，並提升影像邊緣與紋理資訊的復原效果。

4 Dataset and Preprocessing

本專案使用成對的模糊影像與清晰影像作為訓練資料。每一筆資料皆包含一張模糊影像作為模型輸入，以及其對應的清晰影像作為目標輸出。為了使模型能夠穩定學習影像去模糊轉換，資料前處理主要包含影像讀取、資料配對、影像格式轉換、正規化與資料切分等步驟。

首先，所有影像皆轉換為 RGB 格式，確保不同來源影像在通道數與資料格式上保持一致。接著，將影像像素值由原始 $[0, 255]$ 範圍正規化至 $[0, 1]$ 區間，以提升模

型訓練穩定性。模型訓練時，影像以 tensor 格式輸入，並採用 channel-first 格式，即 (C, H, W) 。

資料集進一步切分為 training set、validation set 與 test set。Training set 用於模型參數學習，validation set 用於觀察訓練過程中的泛化表現與選擇最佳 checkpoint，test set 則作為最終模型評估使用。此切分方式可避免模型表現僅反映訓練資料上的擬合能力，而能更客觀地檢驗模型對未見影像的去模糊效果。

在 V2 Ultimate 與 V2 Ultimate-FT 階段，本專案進一步加入 paired data augmentation。由於影像去模糊屬於 paired image-to-image learning，模糊影像與清晰影像必須套用相同的資料增強操作，以維持兩者之間的像素對應關係。本專案採用水平翻轉、垂直翻轉與 90 度旋轉作為資料增強方式，以提升模型對不同影像方向與局部結構的泛化能力。

圖 ?? 顯示本專案影像去模糊任務的資料形式。左圖為模糊影像，中圖為模型輸出之去模糊影像，右圖為對應的清晰目標影像。透過此種視覺化比較，可直接觀察模型是否能改善影像邊緣、細節與整體清晰度。




Figure 1: Example of paired training data for image deblurring.

5 Proposed Method

5.1 Overview

本專案的核心方法為 CNN-based residual image deblurring model。模型以模糊影像作為輸入，透過卷積層與 residual blocks 學習影像特徵，最後輸出一張殘差影像。此殘差影像代表模型認為原始模糊影像中需要被補強或修正的部分。最終輸出則由原始模糊影像加上模型預測殘差而得。

本文主要以 V2 Ultimate 作為核心模型。相較於較早版本，V2 Ultimate 不僅增加了模型深度，也加入 channel attention、residual scaling、EMA、data augmentation 與 cosine learning rate scheduler。這些設計使模型不僅能學習更豐富的影像特徵，也能在訓練過程中維持較穩定的收斂表現。

在完成 V2 Ultimate 訓練後，本研究再以其最佳 checkpoint 作為 pretrained model，建立 V2 Ultimate-FT。Fine-tuning 的目的不是重新訓練整個模型，而是在 V2 Ultimate 已具備良好去模糊能力的基礎上，以較小 learning rate 進行細部調整。因此，本文在模型架構與訓練曲線分析上主要說明 V2 Ultimate，並以 V2 Ultimate-FT 作為最終測試模型。

圖 2 彙整本文所使用之 V2 Ultimate CNN-based image deblurring model 的整體流程。模型首先由模糊影像 X 擷取低階影像特徵，接著透過 enhanced residual blocks 與 channel attention 學習深層特徵表示，最後預測模糊影像與清晰影像之間的殘差 $\hat{R}$ 。最終輸出則由原始模糊影像與預測殘差相加而得，即 $\hat{Y} = X + \hat{R}$ 。




Figure 2: Workflow of the V2 Ultimate CNN-based image deblurring model. The model predicts residual details from the blurred input image and adds them back to generate the deblurred output.

5.2 Model Evolution

本專案並非僅訓練單一 CNN 模型，而是採取逐步改良的方式建立影像去模糊模型。初始版本為 Original CNN，其核心架構為 residual CNN，包含 4 個 residual blocks，每個 block 由兩層 3×3 convolution layers 與 ReLU activation 組成。模型先透過 5×5 convolution layer 將 RGB 影像轉換至 64 個 feature channels，再經由 residual blocks 學習影像特徵，最後輸出與輸入影像相同大小的殘差影像，並將殘差加回原始模糊影像形成去模糊結果。

在 V2 版本中，本專案將 residual blocks 由 4 個增加至 8 個，使模型具有更大的特徵學習容量。此外，loss function 由原本以 MSE 為主的 hybrid loss，調整為以 L1 loss 為主、MSE 為輔的形式：

$$\mathcal{L}_{V2} = 0.2\mathcal{L}_{MSE} + 0.8\mathcal{L}_{L1}.$$

此設計的目的在於降低 MSE loss 可能造成的過度平滑問題，使模型更重視邊緣與局部紋理細節的復原。

進一步地，V2 Ultimate 版本在 V2 的基礎上加入 enhanced residual block。每個 enhanced residual block 除了包含兩層 3×3 convolution layers 之外，也加入 channel attention mechanism，使模型能根據不同 feature channels 的重要性自動調整特徵權重。此外，該版本使用 residual scaling，將每個 block 的殘差更新幅度乘上 0.1，以提升深層 residual network 訓練時的穩定性。V2 Ultimate 亦加入 data augmentation、exponential moving average、cosine annealing learning rate scheduler 與 early stopping，以改善模型的泛化能力與訓練穩定性。

最後，本專案以 V2 Ultimate 的最佳 checkpoint 作為 pretrained model，進一步建立 V2 Ultimate-FT 模型。Fine-tuning 階段採用較小的 learning rate，使模型在既有去模糊能力的基礎上進行細部調整。其 loss function 改為：

$$\mathcal{L}_{FT} = 0.6\mathcal{L}_{MSE} + 0.4\mathcal{L}_{L1}.$$

其中 MSE loss 與 PSNR 指標具有直接關聯，而 L1 loss 則有助於維持影像結構並降低過度平滑。因此，V2 Ultimate-FT 作為本專案的 final model。

Table 1: Evolution of CNN-based image deblurring models

Model Version	Main Design	Loss Function	Training
Original CNN	4 residual blocks	0.7 MSE + 0.3 L1	AdamW,
V2	8 residual blocks	0.2 MSE + 0.8 L1	AdamW,
V2 Ultimate	12 enhanced residual blocks + channel attention	0.9 Charbonnier + 0.1 MSE	EMA, au
V2 Ultimate-FT	Fine-tuned V2 Ultimate	0.6 MSE + 0.4 L1	Low lear

5.3 V2 Ultimate Model Architecture

V2 Ultimate 是本專案的主要模型，其設計目標是在維持 residual learning 優點的同時，進一步提升模型對不同影像特徵的辨識能力。模型首先透過 head convolution layer 將輸入 RGB 影像投影至 64 個 feature channels。接著，影像特徵會經過 12 個 enhanced residual blocks，每個 block 內部包含 convolution layers、ReLU activation、channel attention 與 residual scaling。最後，模型透過 tail convolution layer 輸出三通道殘差影像，並將該殘差加回原始輸入影像。

Table 2: Architecture of V2 Ultimate CNN-based deblurring model

Component	Operation	Output Channels	Description
Input	RGB blurred image	3	Input image norm
Head	5×5 Conv + ReLU	64	Extract low-level
Enhanced Residual Blocks	12 blocks with 3×3 Conv	64	Learn deep residu
Channel Attention	Global average pooling + 1×1 Conv	64	Reweight feature
Body Tail	3×3 Conv	64	Refine body featur
Global Residual Connection	Feature addition	64	Stabilize feature p
Tail	5×5 Conv	3	Predict residual in
Output	Input + predicted residual	3	Generate deblurre

5.4 Channel Attention

Channel attention 的目的在於讓模型自動判斷不同 feature channels 的重要性。對影像去模糊而言，不同通道可能分別對應到邊緣、紋理、亮度變化或局部結構等資訊。若所有通道都被同等看待，模型可能無法有效集中於對去模糊最重要的特徵。因此，V2 Ultimate 在 enhanced residual block 中加入 channel attention，使模型能根據輸入影像內容動態調整通道權重。

在實作上，channel attention 先使用 global average pooling 將每個 feature channel 壓縮為單一統計量，再透過 1×1 convolution layers 與 sigmoid function 產生通道權重。最後，模型將此權重乘回原始 feature maps，使重要通道被強化，不重要通道被抑制。

5.5 Loss Functions

本專案不同版本採用不同 loss function。Original CNN 使用 MSE 與 L1 組成的 hybrid loss。V2 改以 L1 loss 為主，目的是降低 MSE 可能導致的影像過度平滑。V2 Ultimate 則使用 Charbonnier loss 與 MSE loss 的組合：

$$\mathcal{L}_{Ultimate} = 0.9\mathcal{L}_{Charbonnier} + 0.1\mathcal{L}_{MSE}.$$

Charbonnier loss 可視為 L1 loss 的平滑版本，其形式為：

$$\mathcal{L}_{Charbonnier} = \frac{1}{N} \sum_{i=1}^N \sqrt{(\hat{Y}_i - Y_i)^2 + \epsilon^2}.$$

相較於 MSE loss，Charbonnier loss 對較大的誤差較不敏感，因此在影像復原任務中常被用於提升訓練穩定性與細節保留能力。另一方面，MSE loss 與 PSNR 指標直接相關，因此在 V2 Ultimate 中保留 0.1 的 MSE loss 作為輔助，有助於模型在 PSNR 指標上取得較佳表現。

6 Experimental Settings

模型訓練使用 PyTorch 作為主要深度學習框架。訓練過程中，模型以模糊影像作為輸入，並以對應清晰影像作為監督目標。損失函數用於衡量模型輸出影像與清晰目標影像之間的差異，並透過反向傳播更新模型參數。

本專案的訓練流程可分為以下步驟。首先，讀取模糊影像與清晰影像並進行配對。其次，將影像轉換為 tensor 格式並進行正規化。第三，將資料輸入 CNN model，產生預測殘差並加回原始模糊影像，得到去模糊輸出。第四，計算模型輸出與清晰目標影像之間的 loss。最後，透過 optimizer 更新模型參數，並在 validation set 上觀察模型泛化表現。

Table 3: Training settings of the main model and fine-tuning stage

Item	V2 Ultimate	V2 Ultimate-FT
Role	Main model	Fine-tuned final model
Epochs	150	50
Batch size	128	128
Learning rate	3×10^{-4}	1×10^{-5}
Weight decay	1×10^{-5}	1×10^{-6}
Loss	0.90 Charbonnier + 0.10 MSE	0.60 MSE + 0.40 L1
Augmentation	Flip + Rot90	Flip + Rot90
EMA	Yes	Yes
Scheduler	CosineAnnealingLR	CosineAnnealingLR

Table 4: Model capacity comparison

Model	Number of Blocks	Channels	Parameters
Original CNN	4	64	305,091
V2	8	64	600,515
V2 Ultimate	12	64	946,019
V2 Ultimate-FT	12	64	946,019

在模型評估方面，本專案使用 PSNR 與 SSIM 量化模型去模糊後的影像品質。PSNR 主要衡量模型輸出影像與目標清晰影像之間的像素誤差，數值越高表示重建誤差越小；SSIM 則衡量影像在亮度、對比與結構上的相似程度，數值越接近 1 代表輸出影像與目標影像越相似。

PSNR 可表示為：

$$PSNR = 10 \log_{10} \left(\frac{MAX_I^2}{MSE} \right),$$

其中， MAX_I 表示影像像素值的最大可能值， MSE 表示模型輸出影像與目標清晰影像之間的均方誤差。當模型輸出越接近清晰影像時， MSE 越小，PSNR 則越高。

SSIM 則從亮度、對比與結構三個面向衡量兩張影像的相似程度。相較於 PSNR 主要反映像素層級誤差，SSIM 更接近人眼對影像結構品質的感受。因此，本專案同時採用 PSNR 與 SSIM，以更完整評估去模糊模型的表現。

7 Experimental Results

本節首先以 V2 Ultimate 作為主要模型，說明其訓練與收斂表現；接著以 V2 Ultimate-FT 作為最終測試模型，呈現其於 Set5 與 Set14 測試集上的去模糊結果。此安排的原因在於，V2 Ultimate 能較完整反映本專案主要模型架構與訓練策略，而 V2 Ultimate-FT 則是在其基礎上進行後續微調，以獲得更穩定的最終表現。

7.1 Training Curves of V2 Ultimate

為呈現模型主要訓練過程之收斂情形，本文以 V2 Ultimate model 的 training curves 作為主要說明。圖 3 顯示 V2 Ultimate 在訓練過程中的 loss 與 PSNR 變化。




Figure 3: Training curves of the V2 Ultimate CNN-based image deblurring model.

由 loss curve 可觀察到，training loss 與 validation loss 皆隨 epoch 增加而持續下降，且 validation loss 在後期逐漸趨於平穩，表示模型已逐步收斂，未出現明顯的 overfitting 現象。另一方面，由 PSNR curve 可觀察到，模型於訓練初期即快速提升影像重建品質，之後隨著 epoch 增加呈現穩定上升，最終 validation PSNR 收斂至約 28 dB 以上，顯示 V2 Ultimate 具有良好的學習能力與穩定的泛化表現。

此外，圖中可觀察到 validation PSNR 高於 training PSNR，且 validation loss 低於 training loss。此現象主要與本專案的訓練策略有關。首先，training set 使用 paired data augmentation，因此訓練資料相對較具挑戰性；其次，validation 階段使用 EMA model 進行評估，使驗證表現較平滑且穩定。因此，validation curve 略優於 training curve 屬於合理現象。

在完成 V2 Ultimate 訓練後，本研究再以其最佳 checkpoint 進行 fine-tuning，得到 V2 Ultimate-FT。由於 fine-tuning 階段是以已訓練完成之模型為起點，因此其 loss 與 PSNR 變化幅度相對較小。換言之，fine-tuning 的角色主要在於進一步細修模型參數，而非重新建立去模糊能力。

7.2 Quantitative Results

模型訓練完成後，本專案以 V2 Ultimate-FT 作為 final model 進行測試。測試階段分別於 Set5 與 Set14 兩個測試集上進行評估，並以 PSNR 與 SSIM 作為主要評估指標。

Table 5: Test results of V2 Ultimate-FT CNN-based image deblurring model

Dataset	N	PSNR Before	PSNR After	Δ PSNR	SSIM Before	SSIM After	Δ SSIM
Set5	5	21.55	27.20	+5.65	0.878	0.980	+0.101
Set14	14	20.57	24.91	+4.34	0.881	0.961	+0.080
Set5+Set14	19	20.83	25.52	+4.69	0.880	0.966	+0.086

由表 5 可知，V2 Ultimate-FT model 在 Set5 與 Set14 上皆能有效提升影像品質。在 Set5 上，模型將平均 PSNR 由 21.55 dB 提升至 27.20 dB，增加 5.65 dB；SSIM 則由 0.878 提升至 0.980，增加 0.101。此結果表示模型對 Set5 中的影像具有良好的去模糊能力，能有效恢復影像邊緣與結構細節。

在 Set14 上，模型將平均 PSNR 由 20.57 dB 提升至 24.91 dB，增加 4.34 dB；SSIM 則由 0.881 提升至 0.961，增加 0.080。雖然 Set14 的提升幅度略低於 Set5，但模型仍在 PSNR 與 SSIM 上皆呈現明顯改善，顯示其對較多樣化影像內容亦具有穩定的泛化能力。

若將 Set5 與 Set14 合併觀察，整體測試結果顯示模型將平均 PSNR 由 20.83 dB 提升至 25.52 dB，整體增加 4.69 dB；SSIM 則由 0.880 提升至 0.966，整體增加 0.086。此結果說明，模型不僅能降低模糊影像與清晰影像之間的像素誤差，也能改善影像結構相似度，使輸出結果更接近目標清晰影像。

7.3 Ablation Study

為分析不同設計對影像去模糊效果的影響，本專案將模型訓練過程視為一系列 ablation experiments。Original CNN 作為基礎 residual CNN baseline；V2 版本主要檢驗增加 residual blocks 與調整 loss function 是否能改善復原品質；V2 Ultimate 進一步加入 channel attention、residual scaling、data augmentation、EMA 與 cosine learning rate scheduler；最後，V2 Ultimate-FT 用於檢驗在最佳 V2 Ultimate checkpoint 上進行 fine-tuning 是否能帶來額外改善。

此設計使本專案不僅能比較模糊影像與模型輸出之間的差異，也能進一步分析不同模型設計對最終去模糊品質的貢獻。若 V2 相較於 Original CNN 有更佳的 PSNR 或 SSIM，代表加深 residual blocks 與調整 loss function 具有幫助；若 V2 Ultimate 進一步提升結果，則表示 channel attention、EMA 與資料增強能改善模型的泛化能力；若 V2 Ultimate-FT 在測試集上表現最佳，則說明 low learning rate fine-tuning 對最終模型細節修正具有正面效果。

Table 6: Ablation study of model design

Model	Set5 PSNR	Set5 SSIM	Set14 PSNR	Set14 SSIM
Blurred Input	21.55	0.878	20.57	0.881
Original CNN	26.09	0.972	24.06	0.953
V2	26.50	0.975	24.47	0.957
V2 Ultimate	27.17	0.980	24.87	0.960
V2 Ultimate-FT	27.20	0.980	24.91	0.961

由表 6 可觀察到，Original CNN 相較於 blurred input 已能明顯提升影像品質。在 Set5 上，Original CNN 將 PSNR 提升至 26.09 dB，SSIM 提升至 0.972；在 Set14 上，PSNR 提升至 24.06 dB，SSIM 提升至 0.953。此結果顯示，即使是較基礎的 residual CNN 架構，也已能有效學習模糊影像與清晰影像之間的殘差資訊。

進一步比較 Original CNN 與 V2，可發現 V2 在 Set5 與 Set14 上皆取得更高的 PSNR 與 SSIM。Set5 的 PSNR 由 26.09 dB 提升至 26.50 dB，Set14 的 PSNR 則由 24.06 dB 提升至 24.47 dB。此結果表示，增加 residual blocks 並調整 loss function 後，模型對影像細節與結構的復原能力進一步提升。

V2 Ultimate 相較於 V2 亦持續改善。在 Set5 上，PSNR 由 26.50 dB 提升至 27.17 dB；在 Set14 上，PSNR 由 24.47 dB 提升至 24.87 dB。此結果顯示，V2 Ultimate 所加入的 channel attention、residual scaling、EMA、data augmentation 與 cosine scheduler，有助於提升模型的訓練穩定性與泛化能力。

最後，V2 Ultimate-FT 相較於 V2 Ultimate 僅呈現小幅提升。這是合理的，因為 fine-tuning 並非重新訓練模型，而是在已收斂的 V2 Ultimate checkpoint 上進行低 learning rate 的細部調整。整體而言，ablation results 呈現一致的模型演進趨勢：由 Original CNN 到 V2，再到 V2 Ultimate 與 V2 Ultimate-FT，模型在 Set5 與 Set14 上皆逐步取得更佳的去模糊表現。

““latex

7.4 Model Efficiency and Inference Speed

除了 PSNR 與 SSIM 等影像品質指標外，本專案亦進一步評估不同模型版本的推論速度與模型效率。推論速度測試使用 Set5 與 Set14 共 19 張測試影像，並先將測試影像載入記憶體，以避免將影像讀取時間納入模型推論時間。每個模型皆進行 20 次 warm-up runs，並重複測試 100 次，以計算平均每張影像的 forward-pass inference time。測試裝置為 CUDA GPU。

Table 7: Model efficiency and inference speed comparison

Model	Parameters	Time / Image (ms)	FPS	Device
Original CNN	305,091	23.36	42.81	CUDA
V2	600,515	39.80	25.13	CUDA
V2 Ultimate	946,019	69.82	14.32	CUDA
V2 Ultimate-FT	946,019	69.85	14.32	CUDA

由表 7 可觀察到，隨著模型由 Original CNN 演進至 V2 與 V2 Ultimate，參數量與推論時間皆逐步增加。Original CNN 僅包含 305,091 個參數，平均每張影像推論時間為 23.36 ms，約可達 42.81 FPS，為四個模型中速度最快者。V2 將 residual blocks 由 4 個增加至 8 個後，參數量提升至 600,515，平均推論時間增加至 39.80 ms，約為 25.13 FPS。

V2 Ultimate 進一步加入 12 個 enhanced residual blocks、channel attention、residual scaling 與 body-tail feature refinement，因此參數量增加至 946,019，平均推論時間為 69.82 ms，約為 14.32 FPS。V2 Ultimate-FT 與 V2 Ultimate 使用相同模型架構，因此兩者參數量完全相同，推論速度也幾乎一致。這表示 fine-tuning 主要改變模型權重，而不會增加額外推論成本。

整體而言，Original CNN 與 V2 具有較高的推論效率，適合對速度要求較高的應用情境；V2 Ultimate 與 V2 Ultimate-FT 則犧牲部分推論速度，以換取更佳的去模糊品質。結合前述 ablation results 可知，V2 Ultimate-FT 在 PSNR 與 SSIM 上取得最佳表現，但其推論速度低於較小型模型。因此，本專案的模型演進呈現明確的 trade-off：模型容量與去模糊品質提升的同時，也會帶來較高的計算成本。

7.5 Qualitative Results

除了量化指標外，本專案亦透過視覺化結果觀察模型的去模糊效果。圖 4 顯示模糊影像、模型輸出與清晰目標影像之比較。一般而言，若模型成功學習到去模糊轉換，則輸出影像應能呈現更清楚的邊緣、更明顯的物體輪廓，以及較少的模糊擴散現象。




Figure 4: Qualitative comparison of image deblurring result.

由視覺化結果可觀察到，模型輸出相較於原始模糊影像具有更清楚的局部邊緣與結構輪廓。特別是在物體邊界、紋理細節與亮暗交界處，去模糊後的影像通常能呈現較

佳的清晰度。此結果與 PSNR、SSIM 的量化提升相互呼應，顯示模型確實能改善模糊影像品質。

7.6 Challenging Case Analysis

影像去模糊任務中，部分影像即使在視覺上已有明顯改善，仍可能因為高頻紋理與細節結構過於複雜，而在量化指標上呈現較有限的提升。為了分析模型在較困難影像上的表現，本專案從 Set5 與 Set14 測試結果中，選取 Δ PSNR 最小的影像作為 challenging case。此案例為 Set14 中的 set14_0001_baboon.png。該影像之 PSNR 由 18.76 dB 提升至 20.26 dB，改善幅度為 1.50 dB。雖然模型已明顯改善整體清晰度，但相較於其他測試影像，此案例的量化提升幅度較小，代表其對模型而言較具挑戰性。




Figure 5: Challenging case example from Set14. The selected image is set14_0001_baboon.png, which has the smallest PSNR improvement among the evaluated images.

由圖 5 可觀察到，模型輸出相較於原始模糊影像已有明顯改善，尤其在臉部輪廓、眼睛、鼻子與主要顏色區塊上皆變得更清楚。然而，與 sharp target 相比，輸出影像在毛髮、鬍鬚與背景細碎紋理等高頻細節上仍較不完整。Baboon 影像本身包含大量密集且不規則的紋理，這些細節在模糊後容易產生資訊流失，因此模型即使能恢復主要結構，也難以完全重建所有細節。此結果說明，本模型對整體結構與主要邊緣具有良好的復原能力，但在高度複雜紋理與細碎高頻資訊的重建上仍有改善空間。

8 Discussion

本專案結果顯示，V2 Ultimate 作為主要模型，已能在訓練與驗證資料上展現穩定收斂與良好的影像復原能力。其深層 residual learning 架構、channel attention mechanism、EMA 與 data augmentation 等設計，皆有助於提升模型對邊緣、紋理與高頻細節的修復能力。

相較於直接預測完整清晰影像，殘差學習使模型更集中於學習模糊影像與清晰影像之間的差異，因此較能針對邊緣、紋理與高頻細節進行修正。從測試結果來看，模型

在 Set5 與 Set14 上皆明顯提升 PSNR 與 SSIM，表示此方法不僅能降低像素誤差，也能改善影像結構相似度。

V2 Ultimate 中加入的 channel attention 可幫助模型自動調整不同 feature channels 的重要性。對於去模糊任務而言，部分通道可能更關聯於邊緣，部分通道則可能更關聯於紋理或亮度變化。透過 channel attention，模型能更有效利用這些特徵，進而提升對局部結構的復原能力。此外，residual scaling 與 EMA 則有助於穩定深層模型訓練，使模型在訓練後期維持較平滑的收斂狀態。

在此基礎上，本研究再進一步進行 fine-tuning，得到 V2 Ultimate-FT model。由於 fine-tuning 階段是以已收斂之 V2 Ultimate model 為起點，因此其主要作用在於進一步微調模型參數，而非重新建立模型能力。最終測試結果顯示，V2 Ultimate-FT 在 Set5 與 Set14 上皆獲得良好表現，因此可作為本專案的 final model。

Set5 的改善幅度高於 Set14，可能原因是 Set5 影像數量較少，內容變異相對較低，因此模型較容易取得較高的復原品質。相較之下，Set14 包含較多樣化的影像內容與紋理結構，因此去模糊難度較高。即便如此，V2 Ultimate-FT model 在 Set14 上仍能將 PSNR 提升 4.34 dB，並將 SSIM 提升至 0.961，代表模型具備一定的跨影像泛化能力。

本專案仍有幾個限制。第一，目前主要以 PSNR 與 SSIM 作為量化指標，雖然能反映像素誤差與結構相似度，但不一定完全等同於人眼主觀視覺品質。第二，若訓練資料中的模糊型態與測試影像差異過大，模型泛化能力可能受到影響。第三，殘差學習雖能改善細節修復，但在極端模糊或細節嚴重缺失的情況下，模型仍可能無法完全恢復原始高頻資訊。

未來若進一步延伸本專案，可嘗試加入 perceptual loss，使模型在特徵層級上更接近清晰影像；也可加入 adversarial learning，以提升輸出影像的視覺銳利度。此外，亦可比較不同模型架構，例如 U-Net、ResNet-based model 或 attention-based model，以檢驗更複雜架構是否能進一步提升去模糊效果。

9 Conclusion

本專案以影像去模糊為研究主題，建立 CNN-based image deblurring model，並透過 residual learning 設計，使模型學習模糊影像與清晰影像之間的殘差資訊。此方法能降低直接重建完整清晰影像的學習難度，使模型更集中於修正模糊造成的邊緣與紋理細節損失。

本文主要以 V2 Ultimate 作為核心模型，該模型包含 enhanced residual blocks、channel attention、residual scaling、data augmentation、EMA 與 cosine learning rate scheduler。訓練曲線顯示，V2 Ultimate 在訓練過程中 loss 持續下降，PSNR 穩定上升，並於後期逐漸收斂，表示模型具有良好的學習能力與訓練穩定性。在此基礎上，本專案進一步進行 fine-tuning，建立 V2 Ultimate-FT 作為最終測試模型。

實驗結果顯示，V2 Ultimate-FT model 在 Set5 與 Set14 上皆能有效提升影像品質。在 Set5 上，PSNR 由 21.55 dB 提升至 27.20 dB，SSIM 由 0.878 提升至 0.980；在 Set14 上，PSNR 由 20.57 dB 提升至 24.91 dB，SSIM 由 0.881 提升至 0.961。整體 Set5+Set14 結果顯示，模型可帶來 +4.69 dB 的 PSNR 改善與 +0.086 的 SSIM 改善。

整體而言，本專案展示了深度學習方法在影像復原任務中的應用能力，也說明 residual learning、channel attention 與 fine-tuning 對於影像去模糊問題具有實際幫助。V2 Ultimate-FT model 可作為本專案目前的最終模型，其結果顯示模型能穩定改善模糊影像品質，並具備良好的影像細節復原能力。後續若能結合更進階的模型架構、損失函數與資料增強方法，仍有機會進一步提升模型對複雜模糊影像的復原表現。