

專題研究報告

基於 OpenCV 與 CNN 之文件角點偵測 與透視校正系統

*Document Corner Detection and Perspective Correction
using OpenCV and CNN*

作者：蔡詔歲

中華民國 2026 年 6 月 23 日

Abstract

本專案旨在建立一套文件影像角點偵測與透視校正流程，並比較傳統影像處理方法與深度學習模型在文件角點定位任務上的表現。針對手機拍攝文件常見的傾斜、透視變形、背景雜訊與光照不均問題，本研究先使用資料集提供的 ground truth 四角點建立理想透視校正基準，再建立 OpenCV contour-based baseline，最後訓練小型 CNN 與 pretrained ResNet18 進行四角點座標回歸。

研究方法共分為三個階段。首先，利用資料集提供之真實標註建立四點透視轉換的理想校正基準。其次，透過邊緣偵測、形態學轉換與輪廓分析等技術，建構基於 OpenCV 的傳統影像處理基準模型。最後，開發基於卷積神經網路的角點回歸模型，將角點座標正規化並利用 Smooth L1 loss 進行訓練。學習式模型包含基礎的小型 CNN 架構，以及結合 ImageNet 預訓練權重與高解析度輸入的 ResNet18 backbone。

實驗結果顯示，OpenCV baseline 在複雜背景與文件邊界不完整時穩定性不足，其 mean corner error 為 775.23 pixels；小型 CNN 將 mean corner error 降至 310.48 pixels；進一步使用 pretrained ResNet18 backbone 與 384×384 輸入後，full test set 的 mean corner error 降至 120.32 pixels，median error 為 82.21 pixels。經人工檢查並排除標註不確定、角點不可見或嚴重遮擋案例後，clean test set 的 mean corner error 進一步降至 103.88 pixels。

此外，本專案進一步加入 MIDV-500 與 SmartDoc 2015 Challenge 1 進行外部資料擴充實驗。ResNet18 V2 在混合 test set 上取得 overall mean corner error 41.20 pixels，median error 為 18.14 pixels。不過，依資料來源分組後可發現，SmartDoc 與 MIDV-500 subset 表現較佳，而 Original subset 仍具有較高誤差，顯示資料來源、文件類型與標註品質會明顯影響模型評估結果。

整體而言，本專案結果顯示，學習式角點回歸模型相較於傳統 contour-based OpenCV 方法，在本資料集與實驗設定下具有更好的穩定性與準確性。其中，ResNet18 在平均誤差、中位數誤差與不同誤差門檻下的達標比例皆優於其他方法，顯示 pretrained backbone 與較高解析度輸入對文件幾何校正任務具有明顯幫助。同時，本專案也透過 source-wise analysis 與 failure case analysis 指出目前模型仍受資料品質、角點遮擋、文件彎曲與資料來源差異影響。

Contents

1	專案動機與目標	1
2	資料集與標註格式	1
3	方法	2
3.1	Ground Truth 透視校正	3
3.2	OpenCV 自動角點偵測 Baseline	3
3.3	小型 CNN 角點回歸模型	3
3.4	ResNet18 角點回歸模型	4
4	評估指標	4
5	實驗結果	5
5.1	主要方法比較	5
5.2	ResNet18 Clean Test 門檻分析	6
5.3	Clean Test Set 的定位	6
5.4	OpenCV 與 CNN 比較	7
6	外部資料集擴充與 V2 模型實驗	7
6.1	外部資料來源與用途	7
6.2	不同 ResNet18 模型版本設定	8
6.3	V2 模型整體測試結果	8
6.4	不同資料來源之測試表現	9
6.5	高誤差案例與資料品質分析	10
7	圖表結果	10
8	成功案例與失敗案例分析	14
8.1	成功案例	14
8.2	一般案例	15
8.3	失敗案例與資料限制	16
9	討論	17
9.1	OpenCV Baseline 的限制	17
9.2	CNN 與 ResNet18 的改善	17

9.3	資料品質對模型評估的影響	18
9.4	資料來源差異與模型評估限制	18
10	結論	18
A	專案輸出檔案說明	19
	References	20

1 專案動機與目標

在實際應用中，手機拍攝文件影像時常會出現文件傾斜、透視變形、背景雜訊、光照不均或手部遮擋等問題。若文件影像未經校正，後續的文字辨識、文件存檔或影像分析效果都可能受到影響。因此，本專案建立一套文件角點偵測與透視校正流程，將傾斜文件影像轉換為接近正面掃描的結果。

本專案主要目標如下：

- (1) 使用資料集提供的 ground truth 四角點建立理想透視校正結果，作為後續方法比較的基準。
- (2) 建立 OpenCV 自動角點偵測 baseline，評估傳統影像處理方法在文件角點定位任務上的可行性與限制。
- (3) 建立小型 CNN corner regression model，直接預測文件四個角點座標。
- (4) 使用 pretrained ResNet18 backbone 建立角點回歸模型，檢查較深層特徵抽取能力與較高解析度輸入是否能改善角點定位表現。
- (5) 比較 OpenCV baseline、小型 CNN 與 ResNet18 模型在 mean corner error、median corner error 與不同誤差門檻下的表現。
- (6) 加入 MIDV-500 與 SmartDoc 2015 Challenge 1，檢查外部資料擴充後模型在混合資料來源下的表現。
- (7) 透過 source-wise analysis 與 high-error case analysis，分析錯誤來源是否與模型失敗、資料標註不確定性、角點遮擋、文件形變或資料來源差異有關。

本專案並非以 OCR 文字辨識為主要目標，而是聚焦於文件四角點定位與透視校正，屬於文件影像前處理與幾何校正任務。

2 資料集與標註格式

本專案使用 A New Image Dataset for Document Corner Localization 作為實驗資料。此資料集包含多種手機拍攝情境下的文件影像，影像中可能出現不同拍攝角度、透視變形、背景干擾、光照變化、文件彎曲與部分遮擋等情況，因此適合用於評估文件角點定位模型在真實拍攝場景下的表現。相較於乾淨掃描影像，此類手機拍攝資料更接近實際文件數位化流程中會遇到的問題，也更能檢驗模型在非理想條件下的穩定性。

資料集中每張文件影像皆對應一個 CSV 標註檔，CSV 內包含文件四個角點座標與拍攝手機型號。單筆標註格式如下：

$x_1, y_1, x_2, y_2, x_3, y_3, x_4, y_4, \text{camera model}$

其中 (x_i, y_i) 表示文件角點於原始影像中的 pixel 座標。由於原始 CSV 的角點順序不一定固定，因此本專案會先將四個角點重新排序為：

top-left, top-right, bottom-right, bottom-left

角點排序完成後，才能穩定進行四點透視轉換，避免因角點順序錯誤導致輸出影像上下顛倒或幾何形變異常。此步驟同時也有助於後續 CNN 模型學習一致的輸出格式。

為了訓練 CNN 模型，本專案將 pixel 座標正規化至 0 到 1：

$$x_{\text{norm}} = \frac{x}{W}, \quad y_{\text{norm}} = \frac{y}{H}$$

其中 W 與 H 分別為原始影像寬度與高度。模型訓練時輸出八個正規化座標值：

$$[\hat{x}_{tl}, \hat{y}_{tl}, \hat{x}_{tr}, \hat{y}_{tr}, \hat{x}_{br}, \hat{y}_{br}, \hat{x}_{bl}, \hat{y}_{bl}]$$

使用正規化座標的原因是原始影像尺寸並不完全一致，若直接以 pixel 座標訓練模型，座標尺度會受到影像解析度影響。將座標轉換至 0 到 1 後，模型可學習相對位置關係，並在推論階段再將預測結果還原至原始影像尺寸。

資料整理後共取得 1071 筆有效樣本，另有 23 筆因角點幾何檢查不合理或資料格式問題排除。有效樣本進一步切分為 train、validation 與 test set，如表 1 所示。

Table 1: 原始資料切分結果

資料集	樣本數	比例說明
Train set	749	模型訓練
Validation set	161	模型選擇與超參數調整
Test set	161	最終測試評估
Total valid samples	1071	有效樣本總數

3 方法

本專案整體流程可分為資料讀取、角點排序、模型預測、座標反正規化、透視校正與結果評估六個步驟。首先讀取原始影像與 CSV 四角點標註，並將角點統一排序為左上、右上、右下與左下。接著依不同方法取得預測角點，再將模型輸出的正規化座標轉回原始影像 pixel 座標。最後使用四點透視轉換產生校正後文件影像，並以 mean corner error 與 max corner error 評估角點定位品質。

3.1 Ground Truth 透視校正

第一階段使用 CSV 中提供的 ground truth 四角點進行四點透視轉換。此階段的目的是進行自動偵測，而是建立理想角點條件下的校正結果，作為後續模型比較的基準。

給定排序後的四個角點：

$$P = \{p_{tl}, p_{tr}, p_{br}, p_{bl}\}$$

透視轉換會將其映射至矩形輸出平面：

$$D = \{(0, 0), (W' - 1, 0), (W' - 1, H' - 1), (0, H' - 1)\}$$

其中 W' 與 H' 由文件上下邊與左右邊長度估計。透視矩陣 M 透過 OpenCV 的 `getPerspectiveTransform` 計算，並使用 `warpPerspective` 取得校正後文件影像。

3.2 OpenCV 自動角點偵測 Baseline

第二階段建立不依賴 CSV 標註的 OpenCV 自動角點偵測方法。流程包含：

- (1) 將原始影像縮放至固定寬度，降低運算量。
- (2) 轉為灰階影像並使用 CLAHE 增強局部對比。
- (3) 使用 Gaussian blur 降低雜訊。
- (4) 以多組 Canny threshold 產生邊緣圖。
- (5) 使用 dilation 與 morphological closing 強化邊界連續性。
- (6) 透過 contour detection 找出候選文件輪廓。
- (7) 使用 `approxPolyDP` 與 `minAreaRect` 取得四邊形候選。
- (8) 依照面積比例、凸性、邊長與長寬比篩選合理四邊形。

OpenCV baseline 的優點是可解釋性高且不需訓練資料，但在背景複雜、文件邊界不完整、文件彎曲或角點被遮擋時容易偵測失敗。

3.3 小型 CNN 角點回歸模型

第三階段建立小型 CNN corner regression model。模型輸入為 224×224 RGB 影像，輸出為八個正規化角點座標。模型由多層 convolution、batch normalization、

ReLU、max pooling 與 fully connected layers 組成，最後一層使用 sigmoid 函數將輸出限制在 0 到 1。

模型使用 Smooth L1 loss 訓練：

$$\mathcal{L} = \frac{1}{8} \sum_{j=1}^8 \text{SmoothL1}(\hat{y}_j - y_j)$$

其中 $\hat{y}_j$ 為模型預測的正規化座標， y_j 為 ground truth 正規化座標。

3.4 ResNet18 角點回歸模型

為提升模型特徵抽取能力，本專案進一步使用 pretrained ResNet18 作為 backbone。相較於自建小型 CNN，ResNet18 具有更深層의 卷積特徵與 ImageNet 預訓練權重，能更穩定地擷取文件邊界與角點相關特徵。

ResNet18 模型設定如下：

- Input size：384 × 384
- Backbone：pretrained ResNet18
- Output：8 個正規化角點座標
- Loss function：Smooth L1 loss
- Optimizer：AdamW
- Scheduler：ReduceLROnPlateau
- Data augmentation：brightness and contrast adjustment、Gaussian blur、Gaussian noise

提高輸入解析度的原因是文件角點屬於局部幾何特徵，若輸入解析度過低，角點與邊界細節容易在 resize 過程中被壓縮。因此 ResNet18 版本將輸入尺寸由 224 × 224 提高至 384 × 384。

4 評估指標

本專案主要使用 mean corner error 與 max corner error 評估角點定位精度。模型輸出的正規化座標會先轉回原始影像 pixel 座標，再與 ground truth 角點比較。

對於第 i 張影像，第 k 個角點的 pixel error 定義為：

$$e_{ik} = \sqrt{(\hat{x}_{ik} - x_{ik})^2 + (\hat{y}_{ik} - y_{ik})^2}$$

其中 $(\hat{x}_{ik}, \hat{y}_{ik})$ 為預測角點， (x_{ik}, y_{ik}) 為 ground truth 角點。

Mean corner error 定義為四個角點誤差的平均：

$$\text{Mean Corner Error}_i = \frac{1}{4} \sum_{k=1}^4 e_{ik}$$

Max corner error 則定義為四個角點中最大的誤差：

$$\text{Max Corner Error}_i = \max_{k=1, \dots, 4} e_{ik}$$

Mean corner error 可反映整體角點定位精度，而 max corner error 可檢查是否存在單一角點嚴重偏移的情況。

需要注意的是，pixel-level corner error 會受到原始影像解析度與文件在影像中所佔比例影響。若文件面積較小，即使角點只有少量相對位置偏移，也可能造成較大的 pixel error；相反地，若文件佔據影像大部分區域，pixel error 對視覺校正結果的影響可能較容易解讀。因此，本文主要使用 mean corner error 與 max corner error 作為直觀評估指標，未來可進一步加入 normalized corner error，例如以影像對角線或文件對角線進行標準化，以便更公平地比較不同解析度與不同文件大小的影像。

5 實驗結果

5.1 主要方法比較

表 2 顯示 OpenCV baseline、小型 CNN、ResNet18 full test 與 ResNet18 clean test 的角點定位結果。OpenCV baseline 在 CNN test images 中有 135 張成功偵測，mean corner error 為 775.23 pixels。小型 CNN 在 test set 上將 mean corner error 降至 310.48 pixels。使用 pretrained ResNet18 backbone 後，full test set 的 mean corner error 進一步下降至 120.32 pixels。經人工檢查並排除標註異常、角點不可見或嚴重遮擋樣本後，clean test set 的 mean corner error 降至 103.88 pixels。

Table 2: 不同方法之角點定位結果比較

方法	測試樣本數	Mean error	Median error	備註
OpenCV baseline	135	775.23	767.21	僅計算成功偵測樣本
Small CNN	161	310.48	245.32	224 × 224 input
ResNet18 full test	161	120.32	82.21	384 × 384 input
ResNet18 clean test	152	103.88	79.59	排除 9 張異常樣本

需要注意的是，OpenCV baseline 並非所有 test images 都能成功偵測到合理四邊形，因此表中 OpenCV 的樣本數為 135，僅包含成功產生有效角點的影像。

相對地，小型 CNN 與 ResNet18 屬於座標回歸模型，所有 test images 皆可輸出四個角點座標，因此其測試樣本數為 161。換言之，OpenCV baseline 的結果只反映「成功偵測案例」中的誤差，尚未包含完全偵測失敗的影像；若將偵測失敗視為不可用結果，其實際穩定性會更低。

整體而言，ResNet18 clean test 相較於 OpenCV baseline，可將 mean corner error 由 775.23 pixels 降至 103.88 pixels；相較於小型 CNN，亦可將 mean corner error 由 310.48 pixels 降至 103.88 pixels。此結果顯示 pretrained backbone 與較高解析度輸入能明顯改善文件角點定位效果。

5.2 ResNet18 Clean Test 門檻分析

除了平均誤差外，本專案進一步統計 ResNet18 clean test set 中，不同 mean corner error 門檻下的達標比例，如表 3 所示。

Table 3: ResNet18 clean test set 在不同誤差門檻下的表現

Mean corner error 門檻	張數	比例
≤ 50 px	35 / 152	23.0%
≤ 100 px	98 / 152	64.5%
≤ 150 px	125 / 152	82.2%
≤ 200 px	136 / 152	89.5%
≤ 250 px	144 / 152	94.7%
≤ 300 px	147 / 152	96.7%
≤ 400 px	149 / 152	98.0%
≤ 500 px	150 / 152	98.7%

結果顯示，在 clean test set 中，ResNet18 有 89.5% 的影像 mean corner error 低於 200 pixels，且 96.7% 的影像低於 300 pixels。這表示模型在大多數標註合理且四角點可辨識的影像中，能穩定預測文件大致角點位置。若從實務角度來看，文件透視校正通常不只要要求單一角點完全精準，而是要求四個角點能形成合理的文件區域；因此，門檻分析比單純平均值更能反映模型輸出是否具有可用性。

5.3 Clean Test Set 的定位

Clean test set 並非用於取代 full test set，而是作為資料品質敏感性分析。Full test set 反映模型在完整資料條件下的整體表現；clean test set 則用於觀察在角點標註明確且四個角點可辨識的樣本中，模型本身的定位能力。

本專案在人工檢查 high-error cases 後，發現部分樣本的高誤差並非完全來自模型預測失敗，而是與資料本身有關，例如文件角點不可見、僅有三個角點清楚可辨識、文件嚴重彎曲或 ground truth 標註不確定。這類案例若直接納入同一評估，可能會將資料標註問題與模型能力混在一起。因此，本文同時回報 full test 與 clean test 結果，以避免只呈現較佳數字，也保留完整資料下的模型表現。

5.4 OpenCV 與 CNN 比較

在 OpenCV 與小型 CNN 皆有有效結果的 135 張測試影像中，CNN 有 111 張的 mean corner error 低於 OpenCV，比例為 82.22%。此外，CNN 相較於 OpenCV 的平均誤差改善量為 465.71 pixels，中位數改善量為 464.85 pixels。此結果說明學習式方法在整體穩定性上優於傳統 contour-based detection。

然而，OpenCV 並非在所有案例都較差。當文件邊界清楚、背景單純且輪廓完整時，OpenCV 有時能取得極低誤差。因此，本專案結論並非 CNN 完全取代 OpenCV，而是指出在真實手機拍攝情境下，CNN 與 ResNet18 對背景干擾、邊界不完整與光照變化具有更好的整體穩定性。

6 外部資料集擴充與 V2 模型實驗

為進一步提升模型在不同文件拍攝情境下的泛化能力，本專案在原始文件角點資料集之外，額外加入 MIDV-500 與 SmartDoc 2015 Challenge 1 作為外部資料來源。MIDV-500 主要包含手機拍攝之身分證、卡片與護照類文件，可補充不同光照、背景與透視角度下的文件影像；SmartDoc 2015 Challenge 1 則以手機拍攝文件區域偵測為主要任務，較接近本專案的文件擷取與角點定位情境。

然而，不同資料來源的文件類型與任務定義並不完全相同。例如，MIDV-500 多為身分證與卡片，其長寬比例與一般文件資料不同；SmartDoc 雖然較接近文件拍攝任務，但其影像條件、標註方式與原始資料集仍存在差異。因此，本節除了回報整體模型表現外，也進一步依資料來源進行分組分析，以檢查模型在不同來源資料中的表現差異。

6.1 外部資料來源與用途

表 4 整理本專案後續實驗中使用之外部資料來源。相較於原始資料集，外部資料的加入目的並非單純增加資料量，而是補充不同文件拍攝情境，並檢查模型在不同資料來源下的穩定性。

Table 4: 外部資料集與用途說明

資料來源	資料特性	加入目的
Original Dataset	手機拍攝文件角點資料	作為主要訓練與基準資料
MIDV-500	身分證、卡片與護照類影像	補充手機拍攝、背景變化與透視角度
SmartDoc 2015 CH1	手機拍攝文件 frame 與文件四邊形標註	補充文件擷取與角點定位情境

6.2 不同 ResNet18 模型版本設定

本專案後續建立不同版本的 ResNet18 模型，以檢查資料擴充對角點定位表現的影響。V1 模型僅使用原始資料集訓練；Merged 模型在原始資料集上加入 MIDV-500；V2 模型則進一步加入 SmartDoc 2015 Challenge 1。各版本設定如表 5 所示。

Table 5: 不同 ResNet18 模型版本之資料設定

模型版本	訓練資料來源	實驗目的
ResNet18 V1	Original Dataset	建立原始資料集下的主要模型
ResNet18 Merged	Original Dataset + MIDV-500	檢查證件類文件資料是否改善角點定位表現
ResNet18 V2	Original Dataset + MIDV-500 + SmartDoc 2015 CH1	檢查加入手機拍攝文件資料後的整體表現

V2 模型以 ResNet18 Merged 模型作為初始化權重，並在加入 SmartDoc 2015 Challenge 1 後進行 fine-tuning。訓練過程中使用 384×384 輸入影像、Smooth L1 loss、AdamW optimizer 與 ReduceLROnPlateau scheduler。V2 模型於第 65 個 epoch 取得最佳 validation mean corner error，數值為 40.26 pixels，最後一輪 validation mean corner error 為 40.58 pixels，顯示模型訓練過程已趨於穩定。

Table 6: ResNet18 V2 訓練結果摘要

項目	數值
Total epochs	80
Best epoch	65
Best validation mean corner error	40.26 px
Final validation mean corner error	40.58 px
Final learning rate	6.25×10^{-6}
Training time	約 8.39 小時

6.3 V2 模型整體測試結果

V2 模型在 mixed test set 上共評估 837 張影像，整體 mean corner error 為 41.20 pixels，median corner error 為 18.14 pixels。此結果表示，在加入 MIDV-500 與 SmartDoc 2015 Challenge 1 後，模型於混合資料來源測試集上取得較低的整體誤差。

需要注意的是，V2 mixed test set 與前述 ResNet18 V1 所使用的 Original test set 並非完全相同的測試集合，因此兩者不應被視為嚴格的一對一比較。V2 的 overall performance 可用來觀察模型在混合資料來源下的整體表現，但仍需搭配 source-wise analysis 判斷不同資料來源之間的表現差異。

表 7 顯示 V2 模型在不同 mean corner error 門檻下的達標比例。結果顯示，有 82.80% 的測試影像 mean corner error 小於 50 pixels，92.71% 小於 100 pixels，98.21% 小於 300 pixels。此結果表示 V2 模型在多數測試影像中能夠預測出相當接近 ground truth 的文件角點。

Table 7: ResNet18 V2 test set 在不同誤差門檻下的表現

Mean corner error 門檻	達標比例	說明
≤ 25 px	67.50%	非常精準
≤ 50 px	82.80%	高精度角點定位
≤ 100 px	92.71%	大多數樣本可穩定定位
≤ 150 px	95.58%	可形成合理文件區域
≤ 300 px	98.21%	大部分樣本具有可用校正結果
≤ 500 px	99.04%	僅少數樣本存在嚴重偏移

6.4 不同資料來源之測試表現

雖然 V2 模型的整體測試結果良好，但若依資料來源分組後可發現，不同 subset 的誤差分布差異明顯。表 8 顯示，SmartDoc subset 的 mean corner error 僅 16.22 pixels，MIDV-500 subset 為 26.17 pixels，但 Original subset 的 mean corner error 達 131.44 pixels，明顯高於另外兩個資料來源。

Table 8: ResNet18 V2 不同資料來源之 test set 表現

資料來源	樣本數	Mean error	Median error	Max error
SmartDoc	450	16.22	13.20	114.59
MIDV-500	225	26.17	17.91	720.98
Original	162	131.44	75.64	1317.98
Overall	837	41.20	18.14	1317.98

此結果說明，V2 模型整體平均誤差降低，主要來自 SmartDoc 與 MIDV-500 subset 的良好表現。然而，Original subset 仍是高誤差的主要來源。這表示整體平均值雖然能呈現模型在混合資料上的表現，但仍可能掩蓋不同資料來源之間的差異。因此，在文件角點偵測任務中，除了回報 overall performance 外，依資料來源進行分組分析也相當重要。

此結果也顯示，V2 的 overall mean corner error 雖然較低，但主要受到 SmartDoc 與 MIDV-500 subset 表現較佳的影響。若單獨觀察 Original subset，其 mean corner error 仍為 131.44 pixels，顯示原始資料中的複雜背景、文件形變、角點不可見或標註不穩定案例仍是模型主要挑戰。因此，本文不將 V2 的 overall result 解讀為模型已全面解決文件角點偵測問題，而是將其視為外部資料擴充後，在混合資料來源下的整體表現。

6.5 高誤差案例與資料品質分析

V2 模型的 worst-case analysis 顯示，高誤差樣本主要集中於 Original subset。人工檢查後發現，部分高誤差樣本並非標準文件角點定位任務，而是包含文件面積過小、小卡片、鈔票、嚴重反光、角點不可見或 ground truth 標註不穩定等案例。這些情況會使四點角點回歸任務本身變得不明確，也可能導致數值誤差被高估。

高誤差案例大致可分為以下幾類：

- (1) **非標準文件樣本**：影像中目標可能是小卡片、鈔票或非一般文件，與文件掃描任務不完全一致。
- (2) **文件面積過小**：文件在原始影像中佔比過低，導致角點定位對少量 pixel 偏移非常敏感。
- (3) **標註不穩定**：部分 ground truth 四角點不易以視覺確認，或與影像中實際可見文件邊界不完全一致。
- (4) **角點不可見或遮擋**：文件部分角點受手部、背景或反光遮擋，使四點角點回歸任務本身不明確。
- (5) **文件彎曲或非平面形變**：對嚴重彎曲文件而言，單一四邊形無法完整描述文件邊界，因此四點透視校正會受到限制。

因此，V2 模型的高誤差不應完全解讀為模型失敗，而應同時視為資料品質與任務定義不一致的結果。此分析也說明，文件角點偵測模型的效能不只取決於模型架構，也高度依賴資料標註品質與資料來源的一致性。

7 圖表結果

本節放置由程式產生的最終結果圖。這些圖片由 17_make_final_result_summary.py 產生，並儲存在 final_results/figures/ 資料夾中。圖表主要用於比較 OpenCV baseline、小型 CNN、ResNet18 full test 以及 ResNet18 clean test 在文件角點定位任務上的表現。




Figure 1: 不同方法之 mean corner error 比較

圖 1 顯示四種方法的平均角點誤差。OpenCV baseline 的 mean corner error 為 775.23 pixels，明顯高於其他模型，表示傳統邊緣偵測與輪廓分析方法在複雜背景或文件邊界不完整時較不穩定。小型 CNN 將平均誤差降低至 310.48 pixels，顯示學習式方法已能改善傳統方法的限制。ResNet18 full test 進一步降至 120.32 pixels，clean test 則為 103.88 pixels，說明 pretrained backbone 與較高解析度輸入對角點定位有明顯幫助。




Figure 2: 不同方法之 median corner error 比較

圖 2 比較不同方法的中位數角點誤差。中位數較不容易受到少數極端錯誤

案例影響，因此可用來觀察模型在一般案例中的典型表現。OpenCV baseline 的 median error 為 767.21 pixels，小型 CNN 降至 245.32 pixels，而 ResNet18 full test 與 clean test 分別為 82.21 pixels 與 79.59 pixels。full test 與 clean test 的中位數差異很小，表示 ResNet18 在大部分正常樣本中已能穩定預測角點，而 clean test 主要改善的是少數高誤差尾端案例。




Figure 3: mean corner error 小於 300 pixels 之比例比較

圖 3 顯示各方法在 mean corner error 小於 300 pixels 門檻下的達標比例。OpenCV baseline 僅有 18.5% 的樣本低於 300 pixels，小型 CNN 提升至 62.7%，ResNet18 full test 達到 93.8%，clean test 則達到 96.7%。此結果說明 ResNet18 不僅能降低平均誤差，也能讓大多數樣本落在較可用的誤差範圍內。




Figure 4: 不同誤差門檻下之達標比例比較

圖 4 進一步比較不同誤差門檻下的達標比例。OpenCV baseline 在各門檻下比例皆偏低，顯示其整體穩定性不足。小型 CNN 在 300 與 500 pixels 門檻下已有改善，但在 100 pixels 的嚴格門檻下仍偏低，代表其能大致定位文件區域，但精細角點定位能力仍有限。ResNet18 full test 與 clean test 在各門檻下皆優於前兩者，說明其改善不是只發生在少數樣本，而是整體分布都向低誤差區間移動。




Figure 5: 不同方法之 mean corner error 分布

圖 5 使用 boxplot 呈現不同方法的 mean corner error 分布。OpenCV baseline 的分布範圍最廣，且中位數與四分位距皆偏高，表示結果容易受到影像條件影響。小型 CNN 的分布較 OpenCV 收斂，但仍存在明顯變異。ResNet18 full test 與 clean

test 的分布集中在較低誤差區間，顯示模型整體穩定性較佳；clean test 的高誤差尾端較少，也反映部分極端錯誤與資料標註或角點可見性有關。




Figure 6: ResNet18 full test 與 clean test 之誤差分布比較

圖 6 比較 ResNet18 full test 與 clean test 的誤差分布。兩者主要集中在 50 至 150 pixels 之間，表示 ResNet18 對大部分影像皆能達到穩定角點定位。full test 中仍可看到少數高誤差樣本，這些案例多半與標註不確定、角點不可見、遮擋或文件彎曲有關。clean test 排除這些樣本後，高誤差尾端減少，因此平均誤差由 120.32 pixels 降至 103.88 pixels。此結果支持本文同時回報 full test 與 clean test 的做法：前者反映完整資料表現，後者反映有效標註樣本中的模型能力。

綜合上述圖表可以看出，OpenCV baseline 雖然在少數邊界清楚的影像中可能表現良好，但整體穩定性不足；小型 CNN 能有效改善傳統方法的缺點，但仍受限於模型容量與輸入解析度；ResNet18 則在平均誤差、中位數誤差、門檻達標比例與誤差分布穩定性上皆有最佳表現。因此，本專案最終以 ResNet18 corner regression model 作為主要模型，並同時回報 full test 與 clean test 結果，以完整呈現模型在完整資料與有效標註資料下的表現。

8 成功案例與失敗案例分析

8.1 成功案例

在 ResNet18 clean test set 中，最佳案例的 mean corner error 可低於 10 pixels。例如 (602).jpg 的 mean corner error 為 8.63 pixels，max corner error 為 13.61 pixels。此類案例通常具有較清楚的文件邊界，且四個角點皆可辨識，因此模型能準確預測文件角點。



Figure 7: ResNet18 成功案例：ground truth 與預測角點高度接近

8.2 一般案例

一般案例中，ResNet18 通常能預測出合理的文件四角位置，但部分角點可能仍存在輕微偏移。這類偏移會造成透視校正後的文件邊界略有裁切或歪斜，但整體文件區域仍大致正確。



Figure 8: ResNet18 一般案例：模型可大致定位文件區域

8.3 失敗案例與資料限制

ResNet18 的 worst cases 顯示，部分高誤差案例並非完全來自模型失敗，而是與資料特性有關。經人工檢查後，部分影像存在 ground truth 標註不確定、文件角點被遮擋、文件嚴重彎曲，或影像中僅有三個角點清楚可見等情形。這些情況會導致四點角點回歸任務本身不穩定，也會使數值誤差被高估。

本專案人工檢查 ResNet18 high-error cases 後，標記出 9 張應排除於 clean evaluation 的樣本，包括 only three points、invalid label、occluded 與 curved document 等情形。因此，本文同時回報 full test 與 clean test 結果：full test 反映完整資料集下的模型表現；clean test 則反映在標註合理且角點有效樣本中的模型能力。




Figure 9: ResNet18 失敗案例：角點遮擋、標註不確定或文件形變可能造成高誤差

9 討論

9.1 OpenCV Baseline 的限制

OpenCV baseline 依賴邊緣偵測與輪廓分析，因此當文件邊界清楚且背景單純時，能取得相當精準的角點。然而，在本資料集中，許多影像具有手部遮擋、背景紋理、文件彎曲、光照不均或文件內部圖案干擾，這些因素會使 Canny edge 與 contour detection 偵測到錯誤輪廓，導致四角點偏移。

因此，OpenCV baseline 適合作為傳統影像處理方法的比較基準，但不適合作為最終穩定方案。

9.2 CNN 與 ResNet18 的改善

小型 CNN 已能明顯改善 OpenCV baseline 的平均誤差，但由於模型容量有限且輸入解析度只有 224×224 ，對於細小角點與複雜背景的處理能力仍不足。ResNet18 模型使用 ImageNet 預訓練特徵與 384×384 輸入影像，能保留更多邊界細節，因此角點定位效果大幅改善。

實驗結果顯示，ResNet18 clean test set 的 mean corner error 為 103.88 pixels，median corner error 為 79.59 pixels，且 89.5% 的 clean test images 其 mean corner error 低於 200 pixels。此結果說明 pretrained CNN backbone 對文件角點定位任務具有明顯幫助。

9.3 資料品質對模型評估的影響

本專案亦觀察到部分 worst cases 的 ground truth 本身存在不確定性。例如部分影像僅有三個角點清楚可見，或第四個角點被遮擋、超出可辨識範圍。若直接以這些樣本計算 pixel error，模型即使預測出視覺上合理的文件區域，也可能因與 CSV 標註不一致而被視為高誤差。

因此，本專案額外進行人工檢查並建立 clean test set。此做法不是為了任意刪除困難樣本，而是區分「模型真的預測錯」與「標註或影像本身不適合四點校正」兩種情況，使模型評估更具解釋性。

9.4 資料來源差異與模型評估限制

V2 實驗顯示，加入 SmartDoc 2015 Challenge 1 與 MIDV-500 後，模型在 mixed test set 上取得較低的整體角點誤差。然而，依資料來源分組後可發現，SmartDoc 與 MIDV-500 的誤差明顯低於 Original subset。這表示整體平均誤差雖然下降，但模型對不同資料來源的表現並不完全一致。

此現象反映出資料來源差異對文件角點偵測任務的重要影響。不同資料集之間可能在文件類型、文件尺寸、拍攝距離、背景複雜度、光照條件與標註規則上存在差異。若訓練與測試資料中包含大量任務定義不完全一致的樣本，例如身分證、小卡片、文件面積過小或標註不穩定的影像，模型的整體數值結果可能無法完全反映其在特定文件類型上的實際表現。

因此，本專案除了回報 overall performance，也進一步進行 source-wise analysis 與 worst-case analysis。這樣的分析方式可協助區分模型能力、資料品質與任務定義差異三者之間的影響，使模型評估更具解釋性。

10 結論

本專案建立了一套文件角點偵測與透視校正系統，並依序比較 ground truth correction、OpenCV baseline、小型 CNN 與 ResNet18 corner regression model。實驗結果顯示，OpenCV baseline 在複雜背景下穩定性不足，其 mean corner error 為 775.23 pixels；小型 CNN 可將 mean corner error 降至 310.48 pixels；使用 pretrained ResNet18 backbone 與較高解析度輸入後，full test set 的 mean corner error 進一步降至 120.32 pixels。經人工檢查並排除標註不確定或角點不可見案例後，ResNet18 clean test set 的 mean corner error 達到 103.88 pixels，median error 為 79.59 pixels。

此外，本專案進一步透過 MIDV-500 與 SmartDoc 2015 Challenge 1 進行外部資料擴充實驗。結果顯示，加入外部資料後，ResNet18 V2 在 mixed test set 上取得較低的 overall mean corner error，數值為 41.20 pixels。然而，source-wise analysis 顯示，不同資料來源之間仍存在明顯差異，其中 SmartDoc 與 MIDV-500 subset 表現較佳，而 Original subset 仍具有較高誤差。此結果說明，overall performance 可能受到資料組成影響，因此模型效能不僅取決於網路架構，也受到資料來源、文件

類型與標註品質影響。

整體而言，本專案結果支持學習式角點回歸模型相較於傳統 contour-based OpenCV 方法，在本資料集與實驗設定下具有較高的穩定性與準確性。尤其在背景複雜、文件邊界不完整或光照不均的影像中，ResNet18 相較於 OpenCV baseline 與小型 CNN，能更穩定地預測文件四角位置，進而提升透視校正結果的可用性。

不過，本專案仍有幾項限制。首先，本研究主要以四角點座標回歸為核心，對於文件嚴重彎曲、角點不可見或非平面文件變形的處理能力仍有限。其次，模型目前僅預測四個角點，尚未直接處理文件邊界曲線或像素級文件區域，因此面對彎曲紙張或局部遮擋時，四點透視轉換仍可能無法完全校正文件形狀。最後，clean test set 的人工檢查雖可協助釐清資料品質問題，但仍具有一定主觀性，未來可建立更明確的標註品質準則，使資料篩選與錯誤分析更加一致。

未來可進一步嘗試 heatmap-based keypoint detection、YOLO keypoint model 或 document segmentation-based approach。相較於直接回歸八個座標值，heatmap-based 方法可讓模型學習角點的空間機率分布；keypoint detection 方法則能更直接處理角點定位任務；segmentation-based 方法則可先取得文件區域，再從文件 mask 推估邊界與角點。這些方向有助於改善目前模型在文件彎曲、角點遮擋與複雜背景情境下的限制。

A 專案輸出檔案說明

本專案主要輸出檔案如下：

檔案或資料夾	說明
outputs_batch/	使用 CSV ground truth 四角點產生的批次透視校正結果
outputs_auto_batch/	OpenCV 自動角點偵測 baseline 結果
outputs_cnn/	小型 CNN 模型訓練、預測與視覺化結果
outputs_resnet18/	ResNet18 模型訓練、預測、視覺化與 clean evaluation 結果
outputs_resnet18_v2/	加入 MIDV-500 與 SmartDoc 後之 ResNet18 V2 模型訓練與測試結果
outputs_resnet18_v2_test_eval/	ResNet18 V2 test set 評估、source-wise analysis 與 worst-case panels
outputs_comparison/	OpenCV baseline 與小型 CNN 比較結果
final_results/	最終整理後的表格、圖與報告文字

References

- [1] OpenCV Documentation. Open Source Computer Vision Library.
- [2] He, K., Zhang, X., Ren, S., and Sun, J. Deep Residual Learning for Image Recognition. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016.
- [3] Arlazarov, V. V., Bulatov, K. B., Chernov, T. S., and Arlazarov, V. L. MIDV-500: A Dataset for Identity Document Analysis and Recognition on Mobile Devices in Video Stream.
- [4] Burie, J.-C., Chazalon, J., Coustaty, M., Eskenazi, S., Luqman, M. M., Mehri, M., Nayef, N., Ogier, J.-M., Prum, S., and Rusinol, M. ICDAR 2015 Competition on Smartphone Document Capture and OCR.
- [5] A New Image Dataset for Document Corner Localization. Dataset used for document corner localization experiments.